

Machine Learning Canvas

Proyecto: Predicción de popularidad de noticias online

Prediction Task

El objetivo es predecir la popularidad de artículos periodísticos en línea antes de su publicación, utilizando como variable objetivo el número de veces que fueron compartidos en redes sociales (**shares**). Se trata de un problema de **regresión supervisada**, donde se busca estimar un valor numérico continuo.

Decisions

El modelo permitirá a los equipos editoriales y de marketing tomar decisiones basadas en datos, como:

- Destacar artículos con mayor probabilidad de viralizarse.
- Redirigir esfuerzos publicitarios hacia contenidos más prometedores.
- Priorizar temas o categorías con alto nivel de interacción.

Estas decisiones contribuirán a optimizar los recursos de publicación y mejorar el impacto del contenido.

Value Proposition

La implementación de modelos de Machine Learning ofrece a los medios digitales la posibilidad de anticipar el éxito de sus publicaciones, con beneficios como:

- Asistencia automatizada en la selección y promoción de contenidos.
- Reducción de tiempo y costos en campañas inefectivas.
- Identificación de los factores que influyen en la viralidad de los artículos.

Data Sources

El proyecto emplea el dataset **Online News Popularity (UCI)**, que contiene 61 atributos, de los cuales 58 son predictivos, 2 no predictivos (**url**, **timedelta**) y 1 variable objetivo (**shares**). Incluye dimensiones como estructura del texto, análisis de sentimiento, temática, temporalidad y rendimiento en redes sociales.

Durante el preprocesamiento se eliminaron duplicados, se verificó la ausencia de valores nulos y se normalizaron variables booleanas.

Features

El modelo considera distintas características del artículo agrupadas en cinco categorías principales:

- **Texto y tono:** variables como `n_tokens_content` o `global_subjectivity`, que reflejan la extensión y el sentimiento del contenido.
- **Estructura y medios:** número de imágenes, vídeos y enlaces, asociados al atractivo visual.
- **Temática:** canal de publicación (`data_channel_is_tech`, `is_world`, etc.), que influye en el interés del lector.
- **Temporalidad:** día de la semana y variable `is_weekend`, útiles para detectar patrones de publicación.
- **Título y keywords:** polaridad y fuerza semántica del título, relacionadas con su potencial de viralidad.

Building Models

El enfoque del proyecto es de **regresión supervisada**. Se entrenarán y compararán los siguientes modelos:

- Elastic Net
- MLPerceptron
- Random Forest
- HistGradientBoosting

Evaluación: las métricas utilizadas serán MSE, MAE y R^2 .

Making Predictions

Las predicciones se realizarán en Google Colab usando el dataset limpio. Se compararán los valores reales y estimados de **shares** para evaluar el rendimiento del modelo.

Impact Simulation

Resultados esperados:

- Determinar las características más influyentes.
- Lograr un R^2 superior a 0.6 y bajo MAE.
- Evaluar el desempeño comparativo de los modelos.

Monitoring

Aunque aún no se cuenta con despliegue continuo, se usará DVC y GitHub para versionar datasets y modelos, registrar métricas y asegurar reproducibilidad.